

GFPGAN 适用性报告

吴止境

2026 年 7 月

摘要

本报告评估 GFPGAN 是否适合作为远场监控人脸身份识别的默认前处理。正式实验以 MEVID actor check-in 正面照建立固定 ArcFace Gallery，并对 316 条官方 Query 轨迹独立选择 face-best；A 组使用原始对齐脸，B 组对全部可对齐脸运行 GFPGAN，C 组按冻结的产品门控从 A/B 缓存派生。156 条 Query 具有可对齐人脸，其中 40 条属于产品定义的 recoverable 组。该组原图 Rank-1 为 26/40 (65.0%)，GFPGAN 后降至 8/40 (20.0%)；没有样本由错变对，18 条由对变错，配对净变化为 -45 个百分点 (95% bootstrap 置信区间 $[-60, -30]$, $p = 7.63 \times 10^{-6}$)。GFPGAN 使 CR-FIQA 原始分数平均增加 0.483，但修复前后 ArcFace embedding 平均余弦仅为 0.402，说明视觉质量改善没有转化为身份保持。结论是：GFPGAN 可以保留为人工查看的画面增强功能，但不应作为当前产品和 MEVID 监控条件下的默认身份识别前处理。

关键词：GFPGAN；监控人脸；ArcFace；CR-FIQA；身份识别；超分门控

1 结论

我认为 GFPGAN 适合以下场景：

- 改善旧照片、低清照片和监控画面的视觉效果；
- 降低噪点、压缩块和部分模糊，方便人工查看；
- 生成人眼看来更完整、更自然的人脸。

我不建议把 GFPGAN 默认用于当前远场监控身份识别链路。正式配对实验表明，GFPGAN 在 recoverable 组中把 Rank-1 从 65.0% 降到 20.0%，且没有救回任何原本错误的样本。身份识别要求修复后的细节仍然属于同一个人，而 GFPGAN 首先保证的是人脸看起来自然；当输入质量较差时，这两个目标会发生冲突。

因此，我对当前产品的建议是：

GFPGAN 可以保留为画面增强功能，但身份识别默认使用原始对齐脸。当前证据不支持在 direct、recoverable 或 unusable 人脸上默认把 GFPGAN 接入 ArcFace。

2 GFPGAN 不适合作为默认识别前处理的原因

2.1 生成的合理细节不一定是真实细节

GFPGAN 不是普通插值。它先去除模糊、噪声和压缩痕迹，再利用预训练 StyleGAN2 中学到的人脸规律补充眼睛、皮肤、头发和轮廓 [1]。这种生成式人脸先验让它可以从很差的输入中得到自然结果。

GFPGAN 在训练时加入了身份保持损失，希望修复前后仍然是同一个人 [1]。但是，当原图中的眼睛、皱纹或脸部边界已经无法辨认时，模型没有足够依据恢复真实细节，只能生成一个最合理的结果。

GFPGAN 官方模型说明也列出了身份变化和美化倾向：V1.3 可能产生轻微身份变化，V1.2 的结果更锐利，但带有更明显的美化效果¹。这说明视觉自然、清晰度和身份保持并不是同一个目标。

2.2 像素太少时没有足够信息可恢复

远场监控人脸经常只有十几或二十多个像素。此时眼睛、发际线、皱纹和脸部边界可能只剩几个像素。把图片放大到更高分辨率，只增加了输出像素，并没有增加摄像头当时记录到的信息。

同一张低清人脸可以对应多张不同的高清人脸。PULSE 展示过，同一个低清输入可以生成多张看起来都合理、但人物外观不同的高清结果 [3]。这说明极低分辨率人脸不存在唯一恢复答案。

因此，超分必须有限。没有检测到脸、疑似误检、极端姿态或小到无法确认五官的输入，不应进入 GFPGAN，也不应继续判断身份。


2.3 去噪和磨皮可能改写身份特征

GFPGAN 通常能较好地去除噪点和压缩痕迹，但也容易让皮肤变得平滑。额头细纹、眼周纹理、鼻唇沟和局部阴影可能被减弱或重新绘制。


噪点通常是干扰，去除噪点可能有利于识别。但稳定的轮廓、眼周结构和中尺度纹理可能与身份有关。GFPGAN 无法始终准确区分“应该去掉的噪声”和“应该保留的真实纹理”。

图 1 中，修复图更干净、更锐利，但皱纹、皮肤颗粒和局部明暗也发生了变化。图像恢复研究已经证明，视觉质量提高可能伴随对原图忠实程度下降 [2]。因此，图片看起来更清楚，不能直接说明 ArcFace 会识别得更准确。

¹<https://github.com/TencentARC/GFPGAN/blob/master/Comparisons.md>



(a) 原图：皱纹、颗粒和局部明暗较明显



(b) 修复图：噪声减少，但部分纹理被平滑或重绘

图 1：生成式修复同时带来去噪和纹理改写。该图用于说明现象，不作为定量实验结果。

3 CR-FIQA 不能保证身份保持

CR-FIQA 用于预测一张人脸是否适合交给识别模型 [4]。我原本计划根据 FIQA 分数区分 clear、marginal 和 poor，再决定是否建库、识别或超分。

我使用 MEVID 训练身份做过一次诊断。候选数据包含 632 条轨迹，其中 118 条得到有效人脸，最终形成 39 条参考记录和 49 条独立测试记录。

表 1：CR-FIQA 在 MEVID 单帧协议中的诊断结果

项目	结果
ArcFace 第一名正确	9/49 (18.4%)
第一名正确且达到 0.45 阈值	0/49
FIQA 分数与是否认对的相关系数	0.026
不筛选时的第一名正确率	18.4%
过滤最低 10% FIQA 后	20.0%
过滤最低 20% FIQA 后	17.5%
过滤最低 50% FIQA 后	16.0%

FIQA 高分人脸没有表现出更稳定的 ArcFace 识别结果。过滤最低 10% 只产生轻微波动，继续过滤后识别率反而下降。因此，CR-FIQA 不适合作为当前 MEVID 身份识别链路的单一决策依据。

正式 GFPGAN 实验进一步验证了这一点：156 条配对样本的 CR-FIQA 原始分数从平均 1.003 上升到 1.486，平均增加 0.483；但 ArcFace Rank-1 明显下降，修复前后 embedding 平均余弦仅为 0.402。CR-FIQA 衡量识别可用性，但它不能证明生成式修复保留了同一身份。因此，本报告仅把 FIQA 作为诊断变量；在完成独立训练集与客户域校准前，FIQA 不改变质量分桶、超分路

由或 C 组成员，也不能把“FIQA 上升”解释为“身份信息改善”。

4 正式实验设计

4.1 固定 Check-in Gallery 与 Query

实验使用 MEVID actor check-in 正面照作为唯一人脸 Gallery，不使用官方 person ReID Gallery。Check-in 压缩包包含 2,898 张图片和 172 个数字前缀，覆盖全部 104 个 train PID、54 个 test PID 以及 52 个官方 Query PID。官方资料没有单独发布映射表，因此实验同时保存编号覆盖审计与 ArcFace sanity check，避免仅凭文件名假设映射。

Gallery 只接收原始图中 `direct + clear + can_enroll=true` 的人脸。最终选择 343 张 check-in 人脸，形成 145 个身份模板。52 个 Query PID 中，0206 和 0294 没有通过产品建库门控的 check-in 模板；结果保留这些 Query 并明确标记模板不可用，而不是静默删除。

316 条官方 Query 轨迹均被纳入固定 manifest。每条轨迹确定性均匀抽取 24 帧，用便宜的人体上部 ROI 代理维护 Top-3 候选，并加入 body-best 兜底；之后仅在候选上运行人脸检测和质量评估，使用产品共享的 `face_evidence_rank` 选择唯一 face-best。选帧不读取身份预测结果。最终得到 34 条 direct、40 条 recoverable、82 条 unusable 和 160 条 none。

4.2 单轴质量分桶与双轴产品路由

实验准备阶段考虑过两种设计。第一种设计只保留 clear、marginal、poor 和 none 质量类别，再把类别直接映射为原图识别、超分或拒绝。第二种设计同时输出质量类别和 direct、recoverable、unusable、none 可用状态。本实验采用第二种设计。这里的“双轴”不是运行两套互不相关的质量模型：两轴共享尺寸、检测置信度、姿态和模糊度等底层观测，但分别回答“图像质量如何”和“产品应采取什么动作”。

表 2: 单轴质量类别驱动与双轴质量-可用状态设计对比

设计	决策方式	优点与局限
单轴类别驱动	先分为 clear、marginal、poor 和 none，再为每个类别固定一种产品动作。	字段少、解释简单；但 poor 同时包含 25 像素可恢复小脸和 8 像素不可恢复小脸，marginal 也可能同时包含可直接识别与值得尝试增强的样本。类别阈值变化会连带改变产品动作。
双轴设计（采用）	质量类别描述严重程度；可用状态根据缺陷类型和技术下限独立给出 direct、recoverable、unusable 或 none。	能够区分“质量差但可处理”与“质量差且不可恢复”，便于安全拒绝、配置审计和冻结实验；代价是必须在文档和消费方中保持两类字段语义一致。

具体而言，未检测到可用人脸时记为 none；检测分数低于 0.5、极端姿态，或人脸短边低于

20 像素时记为 unusable。通过这些硬门槛后，短边位于 20–28 像素，或模糊程度落入配置化可恢复区间的人脸记为 recoverable；其余可直接使用原图的人脸记为 direct。质量类别不直接决定动作：一个 poor 样本可能因 25 像素小脸而 recoverable，也可能因 8 像素小脸而 unusable；一个 marginal 样本也可能保持 direct。

冻结 manifest 生成时，156 条可对齐 Query 均保存了 CR-FIQA 分数，但 40 条 recoverable 全部由 20–28 像素尺寸规则确定。反事实关闭 FIQA 后，这 40 条的成员完全不变；其中 5 条同时带有 low-FIQA 诊断标签，但该标签不是入组原因。因此，后续多超分后端实验继续复用相同 manifest 和 eligibility，不重新分桶；超分前后 FIQA 只作为诊断统计，不参与 C 组路由或恢复后验收。

4.3 三组固定处理

三组共享同一 check-in Gallery、Query face-best、ArcFace 和 0.45 接受阈值：

表 3: A/B/C 固定处理协议

组别	处理方式
A: 原图	所有已检测并对齐的 face-best 直接进入 ArcFace；这是诊断对照，不代表产品会接受 unusable 样本。
B: 全量超分	所有已检测并对齐的 face-best 先经过确定性 GFPGAN，再进入 ArcFace；GFPGAN 失败时不回退 A。
C: 产品路由	不重新运行 GFPGAN：direct 读取缓存 A，recoverable 读取对应的缓存 B，unusable 和 none 不产生人脸向量；FIQA 不改变该路由。

所有输入、配置、模型权重和结果均保存 SHA256。B 组保存 156 张原始对齐脸、156 张 GFPGAN 脸、embedding 缓存以及 156 张完整对比图；C 组只从缓存派生，不根据识别是否改善选择 A 或 B。

5 正式实验结果

5.1 总体与分组结果

表 4: 按产品 eligibility 分组的 Rank-1 结果。C 在 unusable 和 none 上为 0 是主动拒绝，不是模型预测错误。

Query 组	样本数	A 原图	B 全量 GFPGAN	C 产品门控
全部官方 Query	316	25.3%	14.6%	11.7%
产品可用 (direct+recoverable)	74	74.3%	44.6%	50.0%
direct	34	85.3%	73.5%	85.3%
recoverable	40	65.0%	20.0%	20.0%
unusable	82	30.5%	15.9%	0.0%
none	160	0.0%	0.0%	0.0%

全量百分比包含 160 条 none 以及 C 主动拒绝的 82 条 unusable，因此不能只用全量 Rank-1 评价产品门控。在 74 条产品可用 Query 中，C 为 37/74 (50.0%)，高于 B 的 33/74 (44.6%)：C 保留 34 条 direct 原图，使该组从 B 的 25/34 恢复到 29/34；40 条 recoverable 仍使用缓存 B，因此 B 和 C 同为 8/40。C 在全量统计中反而低于 B，是因为它主动拒绝 82 条 unusable，而 B 仍强制预测并碰巧认对 13 条。产品门控追求的是安全拒绝，不应把这些不可靠预测当作可部署收益。在固定 0.45 阈值下，产品可用组中 C 正确接受 19 条、B 仅 4 条；两者的错误接受分别为 1 条和 0 条，但这里没有独立 impostor cohort，不能称为正式 FMR。

5.2 Recoverable 组的配对结果

Recoverable 组中，A 组 26/40 第一名正确，B 组仅 8/40 正确。配对转换如下：

表 5: Recoverable 组 A→B 的配对转换

转换	数量
原图错误，GFPGAN 后正确	0
原图正确，GFPGAN 后错误	18
两者都正确	8
两者都错误	14
Rank-1 净变化	-45 个百分点
95% bootstrap 置信区间	$[-60, -30]$ 个百分点
精确配对双侧检验	$p = 7.63 \times 10^{-6}$

结果不是由少量极端样本造成：置信区间整体低于 0，且没有任何 recoverable 样本由错变对。Direct 组也从 29/34 降到 25/34；Unusable 组从 25/82 降到 13/82。这些结果一致指向身份信息

损失。

5.3 不同质量层级的审计图

冻结数据中的 category 与 eligibility 并非同义词: 9 条 clear 和 25 条 marginal 均为 direct, 40 条 recoverable 全部为 poor, 另有 82 条 poor 为 unusable。图 2 分别从 clear/direct、marginal/direct 和 poor/recoverable 组中选择 rule_quality 最接近组内中位数的样本, 选择规则不读取 A/B/C 识别结果。




Quality stratum	Check-in Gallery	Original Query (A)	GFPGAN Query (B)
clear/direct PID 0278		 A: 0278 / 0.615	 B: 0278 / 0.297
marginal/di PID 0210		 A: 0210 / 0.416	 B: 0210 / 0.313
poor/recov PID 0277		 A: 0277 / 0.162	 B: 0012 / 0.164

图 2: 按质量层级固定选择的三组 Gallery-原始 Query-GFPGAN Query 审计图。三行依次为 clear/direct (组内 $n = 9$)、marginal/direct ($n = 25$) 和 poor/recoverable ($n = 40$)。Clear 样本的 A/B 分数为 0.615/0.297, marginal 样本为 0.416/0.313; poor/recoverable 样本从 A 正确识别 0277 (0.162) 变为 B 错误识别 0012 (0.164)。每组均按 rule_quality 中位数选择, 视觉展示不参与样本选择和定量统计。




图 3: 预先定义的 recoverable 退化案例：在 A 正确、B 错误的样本中，选择 A 分数最高的一条作审计展示。左起包含真实 check-in Gallery、原始 Query、GFPGAN Query 及错误预测 Gallery。原图对身份 0277 的第一名分数为 0.46；GFPGAN 后第一名变为 0227，分数 0.14。该图仅作单例解释，定量结论来自全部 40 条配对 Query。

5.4 视觉质量上升但身份特征漂移

GFPGAN 在 Tesla T4 上处理 156 张对齐脸，156 次均产生图像并成功提取 embedding。纯增强总耗时 14.80 秒，平均 94.9 毫秒/脸，不含模型首次启动。CR-FIQA 原始分数平均增加 0.483，但修复前后 ArcFace embedding 平均余弦只有 0.402（中位数 0.373）。因此，GFPGAN 的主要问题不是运行失败或速度，而是它生成了更符合人脸先验、却偏离原身份特征的纹理。

全部 156 条 B 样本均保存真实 check-in Gallery、原始 Query、GFPGAN Query 和必要的错误预测 Gallery；没有只展示有利或不利案例。完整结果位于 `/results/checkin_superres_abc_v3`，并已下载校验到本地结果目录。

6 限制

1. MEVID 提供裁剪后的人体轨迹，本实验不能评价全帧人物检测、track ID switch 或脸体关联精度；
2. Check-in 编号完整覆盖 MEVID 身份，且 ArcFace sanity check 支持对应关系，但官方没有单独发布 actor-to-PID 映射表；
3. 52 个 Query PID 中有两个没有合格的 check-in 模板；实验没有独立 impostor Query，因此“错误接受”不能称为正式 FMR；
4. 结论针对 GFPGAN V1.3、ArcFace 和当前 MEVID 监控条件，不能推广为 GFPGAN 对所有画面修复任务都无效。

7 产品建议

现阶段，我建议：

1. 身份识别默认关闭 GFPGAN，direct 人脸继续使用原始对齐脸；
2. 当前 recoverable 状态表示输入满足技术处理下限，不表示 GFPGAN 能恢复身份；在获得新的正向证据前，该状态不应自动进入 GFPGAN 身份分支；
3. 前端可以保留 GFPGAN 画面增强，明确标记为生成式修复结果；
4. CR-FIQA 保留为诊断信号；在独立校准证明其有效前，不用于改变质量分桶、超分路由或恢复后验收；
5. 后续优先改进人脸感知选帧和多帧特征聚合，再评估专门以身份保持为目标训练的超分方法。

参考文献

- [1] X. Wang, Y. Li, H. Zhang, and Y. Shan, "Towards Real-World Blind Face Restoration with Generative Facial Prior," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.
- [2] Y. Blau and T. Michaeli, "The Perception-Distortion Tradeoff," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018.
- [3] S. Menon, A. Damian, S. Hu, N. Ravi, and C. Rudin, "PULSE: Self-Supervised Photo Upsampling via Latent Space Exploration of Generative Models," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.
- [4] F. Boutros, M. Fang, M. Klemmt, B. Fu, and N. Damer, "CR-FIQA: Face Image Quality Assessment by Learning Sample Relative Classifiability," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.